

자기소개 및 지원동기

Black-box 평가를 넘어, 모델 내부 메커니즘을 진단하는 연구로의 확장

DSBA LAB APPLICATION

Ph.D. Candidate



신정운

AI/ML Engineer

CORE COMPETENCIES

LLM Evaluation

RAG Systems

Mechanistic Interpretability

jungwoonshin@gmail.com



문제의식: 평가의 비효율성과 블랙박스의 한계

평가의 비효율성 (Efficiency Bottleneck)

현업 대규모 RAG 시스템 운영 시, 단순 평가를 위해 막대한 추론 자원과 데이터를 소모하는 방식의 한계를 체감

설명력의 부재 (Lack of Explainability)

LLM-as-a-Judge는 정답 여부는 판별하나, "왜 그런 판단을 내렸는지"에 대한 인과관계 설명 불가



지원동기 및 연구 비전

강필성 교수님의 **CheckEval** 연구가 지향하는 '평가의 체계화'에 깊이 공감하며, 이를 모델의 Internal Mechanism 영역으로 확장하고 싶습니다.

RESEARCH APPROACH

기계적 해석 (Mechanistic Interpretability)

결과값이 아닌 모델 내부의 정보 흐름과 사고 과정을 직접 관찰

ULTIMATE GOAL

자원 효율적 (Resource-Efficient) 평가

적은 연산 비용으로 신뢰성 검증이 가능한 프레임워크 제안

연구 및 프로젝트 경험

Theory to Practice: 학술적 연구 역량과 현업의 문제 해결 능력

PORTFOLIO

Research & Industry

_SELECTED PUBLICATIONS

1저자 2020

Bipartite Link Prediction by Intra-class Connection based Triadic Closure

IEEE Access (IF: 4.64)

딥러닝 기반 이분 그래프 링크 예측 알고리즘 제안 및 최신 성능 달성을

공동저자 2019

KitcheNette: Predicting and Recommending Food Ingredient Pairings

IJCAI 2019 (Top Conference)

Siamese Neural Network를 활용한 식재료 조합 예측 및 추천 모델

EDUCATION



고려대학교 컴퓨터과학 석사

2018 - 2020 | GPA 4.00/4.50

DMIS-Lab 연구원 (PyTorch 링크예측 연구)



보스턴대학교(BU) 컴퓨터과학 학사

2011 - 2016

PROFESSIONAL EXPERIENCE



Coxwave

AI/ML 엔지니어

2025.06 - Current

통합 RAG 시스템 개발

LLaVA-Next 및 하이브리드 검색(BM25+BGE-M3) 활용 PDF QA 자동화

임베딩 모델 파인튜닝 (Top-1 Acc 82.8%)

BGE-M3 학습 데이터 최적화(Summary+QA) 및 도메인 취약점 분석



CJ대한통운

데이터 사이언티스트

2023.11 - 2025.05

- VRP 최적화: LP & Heuristic 기반 배송 경로 최적화 및 검증 시스템
- LLM 문서 관리: 한국어 LLaMA + E5 임베딩 기반 사내 RAG 구축
- Transformer 기반 대규모 차량 운행 주문 추천 모델 개발



오버테이크 (Startup)

데이터 사이언티스트

2022.08 - 2023.09

- 금융 추천 시스템 상용화: CTR 모델링으로 클릭 수 5-10배 증대
- 금융위 주최 D-Testbed 신용정보원장상 수상 (대출 증감 예측)

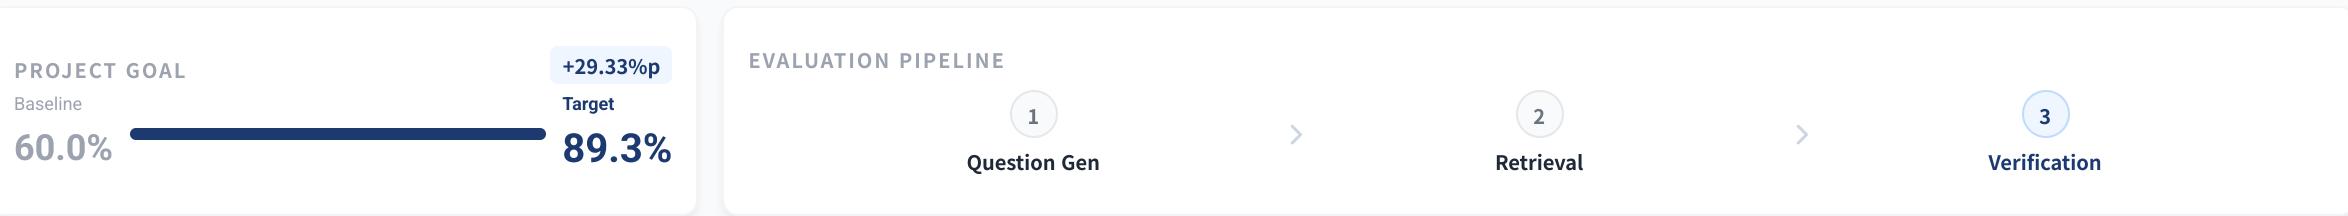
한국어 도메인 특화 RAG 시스템 최적화

교육 QA 시스템의 Document Retrieval Rate 최대화 (60% → 89.33%)

Path: similarity_search/finetune/korean_rag_fine_tuned/doc-train-test

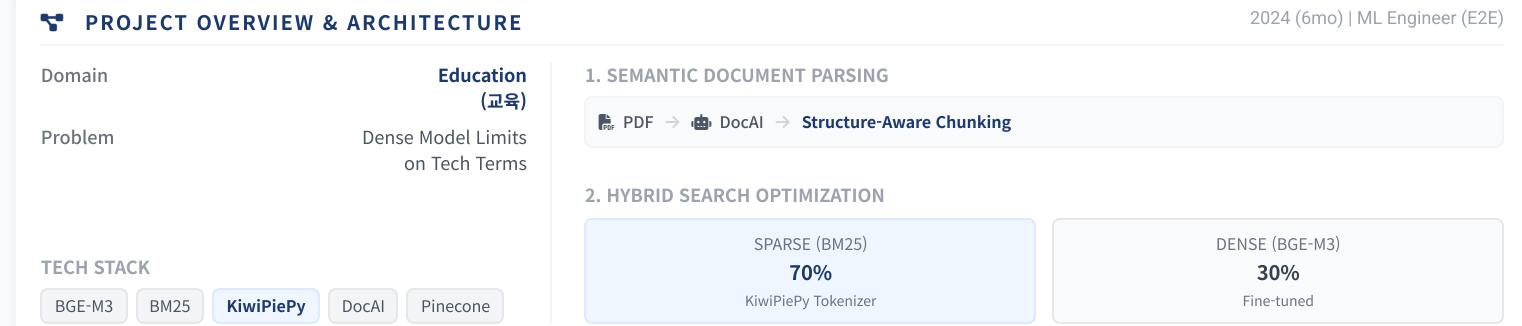
KEY PROJECT 01

Performance Optimization



FINE-TUNING RESULTS

Methodology	Top-1 Acc
QA Multi Pos Neg (1:N)	43.56%
Original (Baseline)	68.12%
Summary	74.69%
Summary + QA Best	83.75%



BEST MODEL DETAIL ANALYSIS

Document Name	Acc	Top-K	Q's	Overall Acc	Top-K Acc	Documents	Questions
[패스트캠퍼스] 클라우드 환경... 파트2_ch1	0.4314	0.7647	51	0.6501	0.8375	11	1,126
[비법노트] 9회 내부회계관리제도	0.8500	0.9167	60				
[Ch3-2. 프로세스와 스레드] 스레드 다루기	0.4478	0.7313	67				
02_01_개체명인식	0.7333	0.8667	15				
1. PT1.CH1.CL1 _ 머신러닝 엔지니어란...	0.5303	0.7424	66				
4. 흐름제어 (조건문, 반복문, 예외처리)	0.5159	0.7778	126				

Document Name

Document Name	Acc	Top-K	Q's
Part04. 배당_강의자료	0.4051	0.6051	195
ubion_23	0.8667	0.9481	135
강의자료_부동산 인허가_29강	0.7204	0.9247	93
01_데이터분석적 사고	0.6667	0.8889	18
ubion_24	0.8100	0.9733	300

Total 11 Documents / 1,126 Questions

금융 상품 추천 시스템 개발 및 상용화

KEY PROJECT 02

행동 로그 분석 기반 개인화 추천 시스템(CTR Prediction) 구축 및 성과

End-to-End Development

OVERVIEW

ROLE & PERIOD

단독 개발 (E2E) | 6 months

OBJECTIVE

무작위 노출의 한계를 극복하고 잠재 고객을 사전 식별하여 추천

KEY ACHIEVEMENT

클릭 수 5~10배 증가

TECH STACK

ML & Modeling

PyTorch torch_fm DeepFM

Data & Pipeline

Pandas LightningDB 50+ Tables

Serving

RESTful API Scheduler

SYSTEM ARCHITECTURE

DATA PIPELINE

LightningDB (50+ Tables) → Feature Eng.

MODEL TRAINING

15 CTR Models Experiment (Grid Search)

FM DeepFM xDeepFM

SERVING API

/train /predict

BUSINESS IMPACT

5-10x

Total Clicks

Random Baseline

↑ 400~900%



AWARD WINNER

금융위 D-Testbed 신용정보원장상

TECHNICAL CHALLENGES

Class Imbalance

Solution: Focal Loss 도입 및 Undersampling 전략, F1 Score 지표 채택

High Cardinality

Solution: Feature Interaction 자동 학습을 위한 FM 계열 모델 및 Embedding 적용

CORE IMPLEMENTATION

CTR 모델 체계적 실험

torch_fm 활용 15개 모델 실험, F1 Score 기반 최적 모델 선정 (Class Imbalance 고려)

대규모 로그 파이프라인

수천 개의 고차원 카테고리 피처를 Embedding Layer로 저차원 학습

Ray 기반 분산 실험

Ray Tune 활용 15개 모델 병렬 투닝(Grid/Random Search) 및 자동화된 모델 선택 파이프라인 구축

향후 연구 계획: White-box LLM 평가 프레임워크

기계적 해석(Mechanistic Interpretability) 관점의 투명하고 효율적인 AI 평가 방법론

RESEARCH PLAN

Ph.D. Roadmap

CONNECTION TO EXPERIENCE

"RAG 프로젝트에서 정확도 89.33%를 달성했으나, 모델이 정말로 검색된 문서를 보고 답했는지, 아니면 환각인지 구분할 수 없었다."

핵심 문제의식: 정답 여부(Output)만으로는 '과정의 타당성'을 검증할 수 없으며, 기존 Judge 모델은 고비용 문제와 사후 탐지의 한계가 존재함.

PARADIGM SHIFT IN EVALUATION

Criteria	Current (Black-box)	Proposed (White-box)
분석 대상	Output (결과값)	Internal State (내부 상태)
평가 주체	External Judge (GPT-4)	Internal Signal (자체 신호)
평가 범위	Correctness (정답 여부)	Process Validity (과정 타당성)

RESEARCH ROADMAP

Exploratory Analysis

내부 활성화 패턴 ↔ 신뢰성 상관관계

- 모델이 정답/환각을 생성할 때, 내부 신경망(Attention, Hidden State)의 차이는 무엇인가?

TARGET Attention Map, Activation Pattern

METHOD 정보 흐름 시각화, Probing Classifier

OUTPUT 신뢰성 판단 Proxy Metric 후보군

01

Causal Mechanism

RAG 정보 인용 메커니즘 인과성 분석

- 모델이 검색된 문서를 실제로 참고했는가? (Context Neglect 탐지)

TARGET Context → Generation 정보 흐름

METHOD Causal Intervention, Attention Attribution

OUTPUT Process-based Eval 프레임워크

02

Framework Dev

자원 효율적 평가 방법론 정립

- 고비용 외부 모델 없이, 내부 신호만으로 답변 품질을 추정할 수 있나?

GOAL 경량화된 Self-evaluation 정립

VALUE Explainability + Cost-efficiency

OUTPUT 범용적 White-box 평가 기준

03

ACADEMIC CONTRIBUTION

Mechanistic Interpretability

RAG Evaluation

Trustworthy AI

PRACTICAL IMPACT

Cost-free Evaluation

Explainable "Why"

Real-time Detection